

UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS UNIVERSIDAD

DEL PERÚ DECANA DE AMÉRICA ESCUELA DE ESTADISTICA ÁREA

DE CIENCIAS MATEMATICAS



**PREDICCIÓN DE BROTES DE MALARIA EN EL PERÚ PARA EL 2027
MEDIANTE USO DE MACHINE LEARNING**

AUTORES:

ESPINOZA LUNA WILDER GILMER

ARAPA LAZO JULIO CESAR

Lima – Perú 2024

Tabla de contenido

I. TÍTULO DEL PROYECTO	3
II. PLANTEAMIENTO DEL PROBLEMA	3
2.1. Descripción y Formulación del problema.....	3
2.2. Objetivos.....	4
2.2.1 Objetivo general	4
2.2.2 Objetivos específicos	4
2.3 Justificación.....	4
III. MARCO TEÓRICO.....	5
3.1 Antecedentes.....	5
3.1.1 Antecedente Internacional	5
3.1.2 Antecedentes Nacionales	6
3.2 Bases teóricas.....	7
3.2.1. Malaria.....	7
IV. METODOLOGÍA DE LA INVESTIGACIÓN.....	24
4.1 Tipo de investigación	24
4.2 Instrumentos de recolección de datos.....	24
4.3 Población y muestra	24
V. ASPECTOS ADMINISTRATIVOS	25
5.1 Cronograma de actividades	25
5.2 Presupuesto del proyecto	27
VI. REFERENCIAS BIBLIOGRÁFICAS	29

I. TÍTULO DEL PROYECTO

Predicción de Incidencia de Malaria en Áreas Geográficas del Perú para el Año 2027 mediante Modelos de Machine Learning.

II. PLANTEAMIENTO DEL PROBLEMA

2.1. Descripción y Formulación del problema

La malaria, una enfermedad parasitaria transmitida por mosquitos, representa un problema de salud pública significativo en Perú. La distribución geográfica de la enfermedad no es uniforme y existen variaciones importantes en la incidencia de malaria entre diferentes regiones del país.

El presente trabajo de investigación busca analizar, mediante machine learning, factores geográficos, tipos de enfermedad, demográficos y temporales con el objetivo de desarrollar modelos que permitan pronosticar la aparición de la malaria en las regiones del Perú.

Entonces, la formulación del problema indica si es posible desarrollar un modelo de predicción preciso y confiable de incidencia de malaria en Perú al 2027, utilizando modelos de Machine Learning y el dataset de Vigilancia Epidemiológica de Malaria del 2000 al 2022, que permita identificar con precisión las áreas con mayor riesgo de malaria.

2.2. Objetivos

2.2.1 Objetivo general

Desarrollar un modelo de predicción preciso y confiable que determine las áreas con mayor riesgo de incidencia de malaria para 2027.

2.2.2 Objetivos específicos

Identificar y mapear mediante machine learning las áreas geográficas con mayor incidencia de malaria utilizando las variables departamento, provincia, distrito, localidad, ubigeo y localcod.

Identificar mediante machine learning patrones entre los diferentes diagnósticos de la malaria utilizando las variables enfermedad y diagnóstico.

Analizar las variables sexo, edad y tipo_edad mediante machine learning para estudiar y buscar patrones en cómo la malaria afecta a diferentes grupos demográficos.

Analizar las variables semana y año para detectar patrones estacionales y tendencias temporales en la incidencia de malaria, mediante machine learning.

2.3 Justificación

La alta incidencia de malaria en el Perú, especialmente en sus regiones amazónicas, representa un desafío significativo para la salud pública y la calidad de vida de sus habitantes. Identificar áreas con alto riesgo de brotes de malaria es crucial para implementar medidas preventivas y de control de manera efectiva.

La utilización de modelos de machine learning para la predicción de la incidencia de malaria en áreas geográficas del Perú para 2027 permitirá una asignación más

eficiente de los recursos de salud pública, que son limitados. Las autoridades sanitarias podrán priorizar sus esfuerzos en prevención y control en las áreas de mayor riesgo, optimizando así el uso de estos recursos.

III. MARCO TEÓRICO

3.1 Antecedentes

3.1.1 Antecedente Internacional

Dukuzumuremyi, (2020). *Machine learning based prediction of malaria outbreak using environment data in Rwanda*. University of Rwanda. Su objetivo fue analizar modelos de predicción sobre brotes de malaria en diez distritos de Ruanda utilizando datos ambientales y casos históricos de malaria, y mediante la aplicación de algoritmos de machine learning, como regresión logística, K-Nearest Neighbours, SVM, Random Forest, Naive Bayes y Decision trees los cuales se evaluaron mediante métricas de rendimiento como Accuracy, Precision, Recall, F-score y AUC score sobre puntuaciones del 0 al 1. Los resultados muestran que Random Forest presenta un alto rendimiento con más del 90% en todas las métricas.

Khan et al., (2024). *Predicting malaria outbreak in The Gambia using machine learning techniques*. Journal PLOS ONE. Este estudio examinó modelos de machine learning para la predicción de brotes de malaria en Gambia. Se utilizaron datos meteorológicos, tamaño de la población y casos de malaria (2013-2021). Se empleó 8 modelos de machine learning ANN, KNN, C5.0 DT, (svmLinear), (svmRadial), XGBoost, RF y LR los cuales se entrenaron, validaron y evaluaron. Los resultados indicaron que una combinación de factores meteorológicos, además del tamaño de la

población y el mes, son importantes para predecir cuándo se producirían epidemias de malaria en una región o distrito particular de Gambia. Los modelos recomendados para la predicción son XGBoost y C5.0 DT.

Nkiruka et al., (2021). *Prediction of malaria incidence using climate variability and machine learning*. Journal ElSevier. Sobre la predicción de la incidencia de malaria utilizando la variabilidad climática. Se analizan seis países del África subsahariana y veintiocho años de datos. Se utilizaron 6 algoritmos de machine para clasificar la incidencia de malaria en alto y bajo riesgo. Descubrieron que tres factores climáticos: precipitación, temperatura y radiación superficial, contribuyen significativamente a los brotes de malaria. El modelo XGBoost superó a otros modelos de clasificación. Esta investigación puede utilizarse para desarrollar sistemas de detección temprana de brotes de malaria.

3.1.2 Antecedentes Nacionales

Sánchez López et al., (2023). *Traditional Machine Learning based on Atmospheric Conditions for Prediction of Dengue Presence*. En esta investigación se analiza la relación entre la incidencia de dengue y las variables meteorológicas en la ciudad de Iquitos, Perú. Para ello, recopilaron datos sobre casos de dengue y variables meteorológicas como la temperatura, la precipitación y la humedad relativa. Se utilizaron cuatro modelos de aprendizaje automático para predecir la presencia de dengue: regresión lineal, K-Nearest Neighbors (KNN), árbol de decisión y máquina de soporte vectorial (SVM). Los resultados del estudio muestran que el modelo SVM tuvo el mejor rendimiento en la predicción de la presencia de dengue.

Singh et al., (2019). *Predicting Dengue Spread in San Juan and Iquitos using Machine Learning Predicting Dengue Spread in San Juan and Iquitos*. Este artículo explora el uso del aprendizaje automático para predecir la propagación del dengue. Se analizan datos ambientales para predecir el número de casos de dengue reportados cada semana en dos ciudades: San Juan, Puerto Rico e Iquitos, Perú. Se utilizaron tres técnicas de modelado diferentes: regresión lineal, redes neuronales artificiales y regresión por gradiente impulsado. Los resultados del estudio muestran que la regresión por gradiente impulsado tuvo el mejor rendimiento en la predicción del número de casos de dengue. Los autores señalan que se podrían realizar mejoras futuras con más datos y mejores modelos.

3.2 Bases teóricas

3.2.1. Malaria

La malaria, una enfermedad parasitaria transmitida por mosquitos, puede proporcionar una base teórica rica para diversas áreas de estudio, como la epidemiología, la biología molecular, la medicina, y la salud pública. Desde una perspectiva epidemiológica, la malaria presenta desafíos únicos en términos de distribución geográfica, factores de riesgo y estrategias de control. Se pueden explorar modelos matemáticos para comprender la propagación y la dinámica de la enfermedad, así como evaluar la eficacia de intervenciones como el control de vectores y la distribución de medicamentos (Bejar Torres, 2023; Failoc-Rojas et al., 2023; Sanchez-Castro et al., 2022) .

Tabla 01.

Atributos de la base de datos “Vigilancia epidemiológica de Malaria”

INDICADORES	TIPO	DENOMINACIÓN	VALORES
departamento	Caracter	Región geográfica	
provincia	Caracter	Provincia	
distrito	Caracter	Lugar probable de infección	
enfermedad	Caracter	Diagnóstico vigilado	
ano	Integer	Año	
semana	Integer	Semana de inicio de síntomas	
diagnostic	Caracter	CIE 10	
tipo_dx	Caracter	Tipo de diagnóstico	C= Confirmado, P = Probable, S = Sospechoso
diresa	Caracter	Dirección de salud que notifica	
ubigeo	Caracter	Código del lugar probable de infección	
edad	Caracter	Edad del paciente	
tipo_edad	Caracter	Tipo de edad del paciente	A = Año, M = Mes, D = Días
sexo	Caracter	Sexo	M = Masculino, F = Femenino

Nota. Esta tabla muestra los indicadores de la base de datos, denominación como también su tipo de variable y sus valores correspondientes si es que lo tienen.

3.2.2 Machine Learning

(Janiesch et al., 2021). *Machine learning and Deep learning*. Scopus. El Machine Learning es una rama de la inteligencia artificial (IA) que se centra en el desarrollo de algoritmos y técnicas que permiten a las computadoras aprender de los datos y mejorar su rendimiento en tareas específicas sin ser explícitamente programadas para ello. A través del Machine Learning, los sistemas pueden identificar patrones, hacer predicciones y tomar decisiones basadas en datos, adaptándose y evolucionando a medida que se les proporciona más información.

Dimensiones de Machine Learning

3.2.2.1 Aprendizaje supervisado

El aprendizaje supervisado es una técnica del aprendizaje automático que utiliza datos etiquetados para entrenar modelos predictivos. Los datos se dividen en conjuntos de entrenamiento y prueba, donde el modelo aprende a predecir las etiquetas de salida correctas a partir de las características de entrada (Dueñas & Rifà, 2020).

El rendimiento del modelo se evalúa utilizando métricas como precisión, recall y error cuadrático medio, y técnicas como la validación cruzada ayudan a asegurar la generalización del modelo. El equilibrio entre el sesgo y la varianza es crucial para evitar el subajuste y el sobreajuste, y algoritmos de optimización como el descenso de gradiente se utilizan para minimizar la función de pérdida y ajustar los parámetros del modelo (Vallalta, 2022).

a. Regresión lineal.

La Regresión Lineal es un método estadístico y de machine learning utilizado para modelar y analizar las relaciones entre una variable dependiente y una o más variables independientes. Este modelo asume que la relación entre las variables es lineal, es decir, que los cambios en la variable dependiente son proporcionales a los cambios en las variables independientes.

Tipos regresión lineal:

a.1. Regresión lineal simple.

Involucran una sola variable independiente, la relación entre la variable independiente X y la variable dependiente Y se representa mediante una línea: $Y = b_0 + b_1X$. Donde b_0 es la intersección (el valor de Y cuando $X = 0$) y b_1 es la pendiente de la línea (cambio en Y por unidad de cambio X) (Rodríguez, 2022).

a.2. Regresión lineal múltiple.

Involucran dos variables independientes y la relación se representa mediante una ecuación de la forma: $Y = b_0 + b_1X_1 + b_2X_2 + \dots + b_nX_n$. Donde $X_1 + X_2 + X_3 + \dots + X_n$ son variables independientes, $b_1, b_2, b_3, \dots, b_n$ son los coeficientes que representan las pendientes con respecto a cada variable independiente y b_0 es la intersección (Díaz López et al., 2023).

Proceso de regresión lineal:

Recopilación de datos, obtener datos relevantes que contienen la variable dependiente y las variables independientes. Preprocesamiento de datos: limpiar y preparar los datos, manejando valores perdidos y normalizando las variables si es necesario. División del conjunto de datos: dividir los datos en conjuntos de entrenamiento y prueba (Camacho, n.d.; Janiesch et al., 2021; Pardo. A, & Ruiz, 2005; Peláez, 2016; Rodríguez, 2022; Rolnick et al., 2023).

Ajuste del Modelo, utilizar técnicas de mínimos cuadrados para encontrar los valores óptimos de los coeficientes ($b_0, b_1, \dots, b_n$) que minimicen la suma de los

errores cuadrados (diferencia entre los valores observados y los valores predichos). Evaluación del modelo: evaluar el modelo usando métricas como el coeficiente de determinación (R^2), el error cuadrático medio (MSE) y otros indicadores de desempeño. Predicción: utilizar el modelo ajustado para hacer predicciones sobre nuevas observaciones (Díaz López et al., 2023).

b. K-Nearest Neighbours

Es un método de aprendizaje supervisado utilizado tanto para clasificación como para regresión. En K-NN, una instancia se clasifica en función de la mayoría de los votos de sus k vecinos más cercanos en el espacio de características. Para la regresión, se toma el promedio de los valores de las k instancias más cercanas. La cercanía entre instancias se mide comúnmente utilizando la distancia euclidiana, aunque pueden usarse otras métricas de distancia. K-NN es un algoritmo no paramétrico y basado en instancias, lo que significa que no hace suposiciones explícitas sobre la distribución de los datos y mantiene todos los ejemplos de entrenamiento en la memoria (Yacoub et al., 2024).

La elección del parámetro k es crucial: un k pequeño puede hacer que el modelo sea sensible al ruido (sobreajuste), mientras que un k grande puede suavizar demasiado la frontera de decisión (subajuste). Aunque K-NN es sencillo y efectivo para datasets pequeños y de baja dimensión, puede ser computacionalmente costoso y menos eficiente para grandes volúmenes de datos debido a su naturaleza basada en instancias y la necesidad de calcular distancias para todas las instancias de entrenamiento durante la predicción (Chamorro-Atalaya et al., 2022).

c. Regresión logística

La regresión logística es una técnica estadística utilizada para modelar y predecir una variable dependiente dicotómica (es decir, una variable que toma dos valores posibles, como sí/no o éxito/fracaso) en función de una o más variables predictoras. La variable dependiente dicotómica es la variable que estamos tratando de predecir o explicar; por ejemplo, si estamos estudiando la probabilidad de que un cliente realice una compra (sí/no), la variable dependiente sería “compra”. Las variables predictoras son las variables independientes que utilizamos para predecir la variable dependiente y pueden ser cuantitativas (como la edad, el ingreso, etc.) o categóricas (como el género, la región, etc.) (Peláez, 2016).

Cuando tenemos variables categóricas, necesitamos convertirlas en variables numéricas para que puedan ser utilizadas en el modelo, y esto se hace mediante la transformación en variables “dummy” (Navarro-Oliva, 2023).

La regresión logística usa la función sigmoide para transformar la salida de una combinación lineal de variables independientes (X) en una probabilidad. Y esta función es:

$$P(Y = 1|X) = \frac{1}{1+e^{b_0+b_1X_1+b_2X_2+\dots+b_nX_n}},$$

donde:


b_0 es la intersección y $b_1, b_2, b_3, \dots, b_n$ son los coeficientes que representan las con respecto a cada variable $X_1 + \dots + X_n$.

d. Árboles de decisión

Este método consiste en dividir iterativamente el espacio de datos en subconjuntos más homogéneos, representando las decisiones en una estructura de árbol donde cada nodo interno corresponde a una prueba sobre un atributo, cada rama representa el resultado de la prueba, y cada nodo hoja representa una clase o un valor de regresión (Alexis et al., 2022).

Componentes de un árbol de decisión: nodo raíz es el primer nodo del árbol, que representa la primera prueba sobre un atributo que divide el conjunto de datos, nodos internos son los nodos que no son hojas y que representan pruebas adicionales sobre atributos del conjunto de datos, ramas que conectan los nodos y representan los resultados de las pruebas en los nodos y nodos hoja son los nodos terminales que proporcionan la predicción final (una clase en clasificación, un valor en regresión) (Araoz Valencia et al., 2023).

Figura 01: Diagrama del árbol de decisión.



Nota: Vicente Rodríguez. *Decision trees / Árboles de decisión para clasificar*

Construcción del Árbol

(Dueñas & Rifà, 2020). La construcción de un árbol de decisión implica seleccionar los atributos más importantes y determinar los puntos de corte óptimos para dividir el conjunto de datos. Los algoritmos comunes para la construcción de árboles de decisión incluyen: ID3 (Iterative Dichotomiser 3) utiliza la ganancia de información para seleccionar el atributo que mejor divide los datos en cada nodo. C4.5 es una extensión de ID3 que maneja atributos continuos y datos incompletos. Y, CART (Classification and Regression Trees) utiliza el índice Gini para clasificación y la suma de los errores cuadrados para regresión (Alexis et al., 2022; Araoz Valencia et al., 2023; Dueñas & Rifà, 2020).

e. Random forest


Los bosques aleatorios son una combinación de predictores de árboles de modo que cada árbol depende de los valores de un vector aleatorio muestreado de forma independiente y con la misma distribución para todos los árboles del bosque. El error de generalización para los bosques converge hasta un límite a medida que aumenta el número de árboles en el bosque. El error de generalización de un bosque de clasificadores de árboles depende de la fuerza de los árboles individuales en el bosque y de la correlación entre ellos

El uso de una selección aleatoria de características para dividir cada nodo genera tasas de error que se comparan favorablemente con Adaboost (Y. Freund & R. Schapire, Machine Learning: Proceedings of the Thirteenth International Conference, 148-156), pero son más sólidas. con respecto al ruido. Las estimaciones internas monitorean el error, la fuerza y la correlación y se utilizan

para mostrar la respuesta al aumento del número de características utilizadas en la división (Schonlau & Zou, 2020).

Figura 01:

Diagrama del modelo Random Forest.



Nota: Janosh Riebesell. *Random Forest / Random Forest para clasificar.*

f. Gradient Boosting (GB)


Es una técnica de aprendizaje automático utilizada para problemas de regresión y clasificación. Se basa en la idea de construir un modelo fuerte a partir de una combinación de varios modelos débiles, como árboles de decisión, mediante un enfoque secuencial y aditivo. El objetivo principal de Gradient Boosting es optimizar una función de pérdida a través de la combinación iterativa de

predicciones de modelos simples y ajustar estos modelos a los residuos (errores) de las predicciones anteriores (Cho et al., 2018).

Gradient Boosting construye el modelo de manera secuencial, agregando nuevos modelos que corrigen los errores de los modelos anteriores. En cada iteración, el algoritmo ajusta un nuevo modelo a los residuos de la predicción anterior, con el objetivo de minimizar la función de pérdida, que mide el error de las predicciones. Utiliza el descenso por gradiente para ajustar los parámetros del modelo, calculando el gradiente de la función de pérdida y moviendo los parámetros en la dirección que reduce el error (Sumayli & Alshahrani, 2023).

Figura 03:

Diagrama de árboles potenciales por gradiente para problemas de regresión.



Nota : Geeksforgeeks. IBM / Árboles potenciados por gradiente para regresión.

g. Redes neuronales

Las Redes Neuronales Artificiales son modelos de aprendizaje automático inspirados en la estructura y función del cerebro humano. Están compuestas por un conjunto interconectado de unidades llamadas neuronas artificiales o nodos, organizadas en capas. Cada neurona toma entradas ponderadas, las suma y aplica una función de activación para producir una salida. Las redes neuronales pueden aprender patrones complejos a partir de datos mediante el ajuste de los pesos de las conexiones entre neuronas, lo que les permite realizar tareas de clasificación, regresión, reconocimiento de patrones y procesamiento de datos no estructurados (Sierra-García & Santos, 2021).

Las redes neuronales tienen la capacidad de modelar relaciones no lineales complejas entre las características de entrada y la salida, lo que las hace adaptables a una amplia gama de problemas en diversos dominios. Además, su capacidad para aprender representaciones jerárquicas de los datos, especialmente en redes neuronales profundas, les permite capturar características cada vez más abstractas y resolver problemas más complejos. Sin embargo, entrenar redes neuronales profundas puede requerir grandes cantidades de datos y recursos computacionales, y su interpretación puede ser difícil debido a su complejidad y naturaleza de caja negra (Díaz López et al., 2023; Sierra-García & Santos, 2021).

3.2.2.2 Aprendizaje no supervisado

El aprendizaje no supervisado es una rama del aprendizaje automático en la que el algoritmo se enfrenta a datos no etiquetados y debe descubrir patrones, estructuras o características intrínsecas en los datos sin la ayuda de una supervisión externa.

A diferencia del aprendizaje supervisado, donde se proporcionan etiquetas para guiar el proceso de aprendizaje, en el aprendizaje no supervisado, el algoritmo debe aprender de manera autónoma a partir de la estructura inherente de los datos.

El aprendizaje no supervisado es útil para explorar y comprender la estructura subyacente de los datos, identificar relaciones ocultas y realizar tareas como agrupamiento (clustering) y reducción de dimensionalidad. Algunos algoritmos comunes en aprendizaje no supervisado incluyen el clustering jerárquico, el k-means, los Modelos de Mezcla Gaussiana (GMM), y el análisis de componentes principales (PCA) (Omar Chamorro-Atalaya, 2022).

h. K-means

K-Means es un algoritmo de agrupamiento no supervisado que divide un conjunto de datos en k grupos (clusters) basándose en la similitud de las características.

Funciona iterativamente asignando cada dato al cluster más cercano al centroide de ese cluster, recalculando luego los centroides basados en los datos asignados, y repitiendo este proceso hasta que la asignación de los datos a los clusters converja (Ahmed et al., 2020).

K-Means es eficiente computacionalmente y fácil de implementar, lo que lo hace adecuado para grandes conjuntos de datos. Sin embargo, su rendimiento puede ser sensible a la elección inicial de los centroides y a la presencia de outliers, lo que puede llevar a soluciones subóptimas. Además, K-Means asume que los clusters son esféricos y de igual tamaño, lo que puede ser una limitación en algunos conjuntos de datos. Se utiliza ampliamente en aplicaciones de segmentación de

mercado, compresión de imágenes, y análisis de datos exploratorios (Sinaga & Yang, 2020).


i. Clustering jerárquico

Es un método de agrupamiento no supervisado que organiza los datos en una estructura de árbol o dendrograma, donde los clusters se pueden subdividir en subclusters de manera jerárquica. En este enfoque, no es necesario especificar el número de clusters de antemano, ya que el algoritmo crea una estructura jerárquica que muestra cómo los datos pueden agruparse a diferentes niveles de granularidad (Valdés García et al., 2021).

El clustering jerárquico puede ser aglomerativo o divisivo. En el enfoque aglomerativo, cada punto de datos comienza como un cluster individual y se fusionan gradualmente en clusters más grandes, mientras que en el enfoque divisivo, todos los datos comienzan en un solo cluster y se dividen en clusters más pequeños. Una ventaja del clustering jerárquico es su capacidad para visualizar la estructura de los datos en diferentes niveles de detalle. Sin embargo, puede ser computacionalmente costoso, especialmente en conjuntos de datos grandes, y la interpretación del dendrograma puede ser subjetiva. Se utiliza en aplicaciones como análisis de expresión génica, clasificación de documentos y taxonomía biológica (Medium, 2023).

Figura 04:

El dendrograma del agrupamiento jerárquico



Nota: Wikipedia / Diagrama de Clustering jerárquico.

j. Modelos de mezcla gaussiana (GMM)

Son un método de aprendizaje no supervisado que modela la distribución de los datos como una combinación de varias distribuciones gaussianas, también conocidas como componentes. Cada componente gaussiana representa un cluster en el espacio de características, y el modelo busca ajustar los parámetros de las gaussianas para capturar la estructura subyacente de los datos. En otras palabras, un GMM asume que los datos provienen de varias distribuciones gaussianas con diferentes medias y varianzas, y el objetivo es estimar estas distribuciones a partir de los datos observados (Martinez Castillo, 2022; Sarmiento et al., 2014).

Los GMM son flexibles y pueden modelar una amplia variedad de distribuciones de datos, desde clusters esféricos hasta clusters con formas más complejas. Además, pueden capturar la estructura de los datos donde la

probabilidad de pertenecer a un cluster varía continuamente en el espacio. Sin embargo, la convergencia del algoritmo de entrenamiento puede ser lenta en conjuntos de datos grandes, y la elección del número óptimo de componentes gaussianas puede ser un desafío. Los GMM se utilizan en aplicaciones como segmentación de imágenes, reconocimiento de patrones, y análisis de datos biomédicos (Martínez, 2022).

3.2.2.3 Aprendizaje por refuerzo

El Aprendizaje por Refuerzo es un paradigma de aprendizaje automático donde un agente interactúa con un entorno dinámico y desconocido con el objetivo de aprender una política óptima para tomar decisiones secuenciales. El agente toma acciones en el entorno, recibe una señal de refuerzo que indica qué tan buenas fueron esas acciones y utiliza esta retroalimentación para mejorar su comportamiento con el tiempo. El objetivo es maximizar la recompensa acumulada a lo largo del tiempo .

El aprendizaje por refuerzo se basa en la idea de aprendizaje a partir de la experiencia. El agente explora el entorno y aprende a través de ensayo y error, utilizando estrategias como la exploración y la explotación para encontrar la mejor política de acción. Este enfoque es especialmente adecuado para problemas donde las acciones del agente afectan el estado futuro del entorno, como en juegos, robótica, gestión de recursos y control de procesos. Sin embargo, el aprendizaje por refuerzo puede enfrentar desafíos como el problema de la exploración frente a la explotación, la maldición de la dimensionalidad y la dificultad de generalizar el conocimiento a entornos nuevos. Se utilizan

algoritmos como Q-learning, SARSA, y algoritmos basados en redes neuronales como Deep Q-Networks (DQN) y Política de Gradiente Profunda (PGP) para abordar una amplia gama de problemas de aprendizaje por refuerzo (Schab et al., 2022; Sierra-García & Santos, 2021).

k. Q-learning

Q-learning es un algoritmo de aprendizaje por refuerzo que permite que un agente aprenda a tomar decisiones óptimas en un entorno desconocido mediante la exploración de un espacio de acciones y estados. El algoritmo utiliza una tabla de valores conocida como función Q, que representa la calidad de tomar una acción en un estado dado. El agente actualiza iterativamente los valores Q utilizando la ecuación de Bellman, que combina la recompensa inmediata con la recompensa esperada de los estados futuros. A través de la exploración y la explotación, el agente converge hacia una política óptima que maximiza las recompensas a largo plazo (Clifton & Laber, 2020).

Una de las características clave de Q-learning es su capacidad para aprender sin requerir un modelo del entorno, lo que lo hace especialmente útil en entornos complejos o estocásticos donde las transiciones de estado no son completamente predecibles. Sin embargo, el algoritmo puede ser susceptible a problemas como la convergencia lenta o el sobreaprendizaje en entornos con grandes espacios de acciones o estados. Además, las extensiones del algoritmo, como el aprendizaje profundo con Q-learning (DQN), han demostrado ser efectivas en la resolución de problemas de mayor escala y complejidad, como los juegos de Atari y el control de robots (Xie, 2024).

I. Deep Q-learning

Es una extensión del algoritmo Q-Learning que utiliza redes neuronales profundas para aproximar la función Q en entornos de aprendizaje por refuerzo de alta dimensionalidad. Al igual que en Q-learning, el objetivo es aprender una política óptima de acción que maximice las recompensas acumuladas a lo largo del tiempo. En lugar de utilizar una tabla Q para almacenar los valores Q para cada par estado-acción, Deep Q-Learning utiliza una red neuronal profunda para aproximar esta función Q (Janiesch et al., 2021).

Una de las características clave de Deep Q-Learning es su capacidad para manejar espacios de estados y acciones de alta dimensionalidad, como en juegos de video o control de robots, donde el número de posibles estados o acciones es demasiado grande para almacenarlos en una tabla. La red neuronal profunda aprende a mapear directamente los estados de entrada a los valores Q para cada acción posible, permitiendo así al agente tomar decisiones en entornos complejos y de gran escala. Sin embargo, Deep Q-Learning también enfrenta desafíos como la estabilidad del entrenamiento y el sobreajuste, que pueden abordarse mediante técnicas como la experiencia de repetición y el aprendizaje objetivo doble. En general, Deep Q-Learning ha demostrado ser efectivo en la resolución de una amplia gama de problemas de aprendizaje por refuerzo, desde juegos de video hasta robótica y control de procesos (Dhana Shree & Logeswari, 2024).

IV. METODOLOGÍA DE LA INVESTIGACIÓN

4.1 Tipo de investigación

La investigación es aplicada Se busca aplicar el conocimiento científico a la solución de un problema en particular o al desarrollo de nuevas tecnologías. Investigación de diseño no experimental, estudios que se realizan sin la manipulación deliberada de variables y en los que solo se observan los fenómenos en su ambiente natural para analizarlos (Hernández-Sampieri, 2018) . De tipo longitudinal ya que se recaban datos en diferentes puntos del tiempo para realizar inferencias acerca de la evolución del problema de investigación, sus causas y efectos (Hernández-Sampieri, 2018)

4.2 Instrumentos de recolección de datos

Los datos fueron obtenidos de los registros generados por las autoridades sanitarias de la Red Nacional de Epidemiología (RENACE), del dataset "Vigilancia Epidemiológica de Malaria" publicado por el Gobierno del Perú en la plataforma de Datos Abiertos en formato csv.

4.3 Población y muestra

Población: Datos históricos de casos de malaria en Perú, conformado por todos los casos de malaria registrados en la Red Nacional de Epidemiología (RENACE). La muestra, lo conforma los casos de malaria en Perú desde los años 2000 al 2022.

V. ASPECTOS ADMINISTRATIVOS


5.1 Cronograma de actividades

En este apartado se detallan las actividades necesarias para la ejecución exitosa de este proyecto de investigación mediante un cronograma de actividades. Este fue desarrollado utilizando la herramienta Power BI, incorporando la extensión Deneb para la visualización de datos. Adicionalmente, la metodología SCRUM fue implementada en la creación del diagrama de Gantt para facilitar una gestión ágil y eficiente de las actividades.

Lo que se visualiza en la (**Figura 05**) son las actividades programadas, comenzando con una fase de planificación para obtener una visión clara de los objetivos a alcanzar. Seguidamente, se realizará un análisis exploratorio que incluirá proyecciones futuras relacionadas con la epidemiología de la malaria, utilizando modelos de machine learning. Después de este análisis exploratorio, se efectuará un proceso ETL (Extracción, Transformación y Carga) para preparar los datos para su modelado y visualización en Power BI. Finalmente, esta parte práctica concluirá con un cierre que incluirá conclusiones e interpretaciones, como se muestra a continuación.

Figura 05

Diagrama Gantt sobre las actividades que se realizarán en el proyecto de investigación.



Nota: Elaboración propia

5.2 Presupuesto del proyecto

El presupuesto del proyecto se ha autofinanciado, asegurando la cobertura total de las necesidades del proyecto de investigación sobre la predicción de la incidencia de malaria en Perú para el año 2027 utilizando modelos de machine learning.

Tabla 02

Presupuesto del proyecto

RECURSOS HUMANOS	CANTIDAD	Suma de COSTO UNITARIO (S/.)	
Investigadores	2	0	
Total	2	0	

Bienes

MATERIALES	CANTIDAD	COSTO UNITARIO (S/.)	COSTO TOTAL (S/.)
Corrector	2	2	4
Hojas bond (por medio millar	0	17	3
Lapicero	10	2	20
Laptop	2	3.000	6.000
Recursos	18	10	180
Total	32	3.031	6.207

Servicios

MATERIALES	CANTIDAD	Suma de COSTO UNITARIO (S/.)	Suma de COSTO TOTAL (S/.)
Internet	4	60	240
Luz	4	50	200
Agua	4	40	160
Gasto de trasporte			500
Total	12	150	1.100

RESUMEN

	COSTO TOTAL (S/.)
Recursos humanos	0
Bienes	6.207
Servicios	1.100
Total	7.307

Nota. Este desglose incluye los costos asociados a la utilización de software especializado, infraestructura tecnológica, y los recursos humanos necesarios para la realización de cada tarea específica. Todos los fondos necesarios fueron gestionados internamente, reflejando un compromiso con la investigación y su impacto potencial en la predicción y manejo de la malaria en Perú.

VI. REFERENCIAS BIBLIOGRÁFICAS

- Ahmed, M., Seraj, R., & Islam, S. M. S. (2020). The k-means Algorithm: A Comprehensive Survey and Performance Evaluation. *Electronics* 2020, Vol. 9, Page 1295, 9(8), 1295. <https://doi.org/10.3390/ELECTRONICS9081295>
- Alexis, A., Apaza, Z., Sair, S., Gárate, O., Javier, A. E., Cuadros, C., Miriam, P., & Ccasa, C. (2022). Modelo predictivo de la potabilidad del agua mediante un árbol de decisión en Inteligencia Artificial Predictive model of water potability through a decision tree in Artificial Intelligence. *Revista Innovación y Software*, 3(2).
- Araoz Valencia, L. E., Huaracha Condori, W., Quispe Quicaña, V. R., & Turpo Coila, A. R. (2023). Aplicación de árboles de decisión para la identificación de adaptabilidad de estudiantes en educación online. *Innovación y Software*, 4(2). <https://doi.org/10.48168/innosoft.s12.a113>
- Bejar Torres, K. A. (2023). Factores relacionados a la alta rotación de personal sanitario en zonas endémicas de malaria de la provincia Satipo. *Boletín de Malariología y Salud Ambiental*. <https://doi.org/10.52808/bmsa.8e7.632.023>
- Camacho, C. (n.d.). *Regresión lineal simple*.
- Chamorro-Atalaya, O., Alvarado-Bravo, N., Aldana-Trejo, F., Poma-Garcia, C., Aliaga-Valdez, C., Peralta-Eugenio, G., & Tasayco-Jala, A. (2022). Supervised learning through k-nearest neighbor, used in the prediction of university teaching performance. *Indonesian Journal of Electrical Engineering and Computer Science*, 27(3), 1625–1634. <https://doi.org/10.11591/IJEECS.V27.I3.PP1625-1634>
- Cho, Y., Yoon, J., & Lee, S. (2018). Using social network analysis and gradient boosting to develop a soccer win–lose prediction model. *Engineering Applications of Artificial Intelligence*, 72, 228–240. <https://doi.org/10.1016/J.ENGAPPAL.2018.04.010>
- Clifton, J., & Laber, E. (2020). *Annual Review of Statistics and Its Application Q-Learning: Theory and Applications*. <https://doi.org/10.1146/annurev-statistics-031219>
- Dhana Shree, K., & Logeswari, S. (2024). ODRNN: Optimized deep recurrent neural networks for automatic detection of Leukaemia. *Egyptian Informatics Journal*, 26, 100453. <https://doi.org/10.1016/J.EIJ.2024.100453>
- Díaz López, M. H., King-Domínguez, A., & Améstica-Rivas, L. (2023). Estimación de Precios de Bitcoin mediante Regresión Lineal Múltiple y Redes Neuronales. *PODIUM*, 44. <https://doi.org/10.31095/podium.2023.44.8>
- Dueñas, J. M., & Rifà, H. (2020). Aprendizaje supervisado para la detección de amenazas web mediante clasificación basada en árboles de decisión. *Máster Universitario En Seguridad de Las Tecnologías de La Información y de Las Comunicaciones*, 1(1).
- Dukuzumuremyi, A. (2020). *African Centre of Excellence in Data Science Topic: Machine learning based prediction of malaria outbreak using environment data in Rwanda*.
- Failoc-Rojas, V. E., Becerra-Silva, F., Chero-Salvador, J., Iglesias-Osores, S., Valladares-Garrido, M. J., & Zeña-Ñañez, S. (2023). Knowledge, attitudes, and practices about malaria in travelers to risk areas in Peru. *Travel Medicine and Infectious Disease*, 52. <https://doi.org/10.1016/j.tmaid.2022.102522>

- Hernández-Sampieri, R. & M. C. (2018). *Hernández-Sampieri, R. & Mendoza, C (2018). Metodología de la investigación. Las rutas cuantitativa, cualitativa y mixta | RUDICS*. Hernández-Sampieri, R. & Mendoza, C. <https://virtual.cuautitlan.unam.mx/rudics/?p=2612>
- Janiesch, C., Zschech, P., & Heinrich, K. (2021). Machine learning and deep learning. *Electronic Markets*, 31(3). <https://doi.org/10.1007/s12525-021-00475-2>
- Khan, O., Ajadi, J. O., & Hossain, M. P. (2024). Predicting malaria outbreak in The Gambia using machine learning techniques. *PLoS ONE*, 19(5). <https://doi.org/10.1371/journal.pone.0299386>
- Martinez Castillo, D. S. (2022, July 5). *Modelos de mezclas Gaussianas como clasificadores en el contexto de machine learning - hdl:11349/33093*. <https://repository.udistrital.edu.co/handle/11349/33093>
- Navarro-Oliva, E. I. (2023). Regresión logística. In *Bioestadística: Guía para un programa académico*. <https://doi.org/10.59760/6959145.14>
- Nkiruka, O., Prasad, R., & Clement, O. (2021). Prediction of malaria incidence using climate variability and machine learning. *Informatics in Medicine Unlocked*, 22. <https://doi.org/10.1016/j.imu.2020.100508>
- Omar Chamorro-Atalaya, N. A.-B. F. A.-T. C. P.-G. C. A.-V. G. P.-E. A. T.-J. (2022). *Supervised learning through k-nearest neighbor, used in the prediction of university teaching performance | Chamorro-Atalaya | Indonesian Journal of Electrical Engineering and Computer Science*. <https://ijeecs.iaescore.com/index.php/IJECS/article/view/28103>
- Pardo, A. & Ruiz, M. A. (2005). Análisis de regresión lineal : El procedimiento Regresión lineal. *Guía Para El Análisis de Datos*.
- Peláez, I. (2016). Modelos de regresión: lineal simple y regresión logística. *Revista Seden*, 14.
- Rodríguez, M. D. (2022). Regresión lineal simple. In *Estadística inferencial aplicada*. <https://doi.org/10.2307/j.ctv2wk71sb.8>
- Rolnick, D., Donti, P. L., Kaack, L. H., Kochanski, K., Lacoste, A., Sankaran, K., Ross, A. S., Milojevic-Dupont, N., Jaques, N., Waldman-Brown, A., Luccioni, A. S., Maharaj, T., Sherwin, E. D., Mukkavilli, S. K., Kording, K. P., Gomes, C. P., Ng, A. Y., Hassabis, D., Platt, J. C., ... Bengio, Y. (2023). Tackling Climate Change with Machine Learning. In *ACM Computing Surveys* (Vol. 55, Issue 2). <https://doi.org/10.1145/3485128>
- Sánchez López, B. S., Candiotti Nolberto, D., Taquíá Gutiérrez, J. A., García López, Y., Sánchez López, B. S., Candiotti Nolberto, D., Taquíá Gutiérrez, J. A., & García López, Y. (2023). Traditional Machine Learning based on Atmospheric Conditions for Prediction of Dengue Presence. *Computación y Sistemas*, 27(3), 769–777. <https://doi.org/10.13053/CYS-27-3-4383>
- Sanchez-Castro, E. E., Cahuana, G. M., García-Ríos, C. J., Guerra-Duarte, C., Chauca, P., Tapia-Limonchi, R., Chenet, S. M., Soria, B., Chavez-Olortegui, C., & Tejedo, J. R. (2022). Health and economic burden due to malaria in Peru over 30 years (1990–2019): Findings from the global burden of diseases study 2019. *The Lancet Regional Health - Americas*, 15. <https://doi.org/10.1016/j.lana.2022.100347>

- Sarmiento, A., Fondón, I., Velasco, M., Qaisar, A., & Aguilera, P. (2014). *Modelo de Mezcla de Gaussianas Generalizadas para Segmentación de Melanomas*.
- Schab, E. A., Piccoli, M. F., & Casanova Pietroboni, C. A. (2022). Analítica Prescriptiva en VRP mediante Aprendizaje por Refuerzo y Flujos de Eventos. *AJEA*, 15. <https://doi.org/10.33414/ajea.1119.2022>
- Schonlau, M., & Zou, R. Y. (2020). The random forest algorithm for statistical learning. *Stata Journal*, 20(1). <https://doi.org/10.1177/1536867X20909688>
- Sierra-García, J. E., & Santos, M. (2021). Redes neuronales y aprendizaje por refuerzo en el control de turbinas eólicas. *Revista Iberoamericana de Automática e Informática Industrial*, 18(4). <https://doi.org/10.4995/riai.2021.16111>
- Sinaga, K. P., & Yang, M. S. (2020). Unsupervised K-means clustering algorithm. *IEEE Access*, 8. <https://doi.org/10.1109/ACCESS.2020.2988796>
- Singh, C., Vidyapeetham, A. V., Openai, A., B, A. M., Divya Vani, C., Barman, S., & Chaurasia, K. (2019). Predicting Dengue Spread in San Juan and Iquitos using Machine Learning Predicting Dengue Spread in San Juan and Iquitos. *ResearchGate*. <https://doi.org/10.13140/RG.2.2.24207.74406>
- Sumayli, A., & Alshahrani, S. M. (2023). *Modeling and prediction of biodiesel production by using different artificial intelligence methods: Multi-layer perceptron (MLP), Gradient boosting (GB), and Gaussian process regression (GPR)*. <https://doi.org/10.1016/j.arabjc.2023.104801>
- Anthony, B. (2023, February 7). *Tutorial del Algoritmo de Agrupamiento Jerárquico en Python | by Anthony Barrios | LatinXinAI | Medium*. Medium. <https://medium.com/latinxinai/tutorial-del-algoritmo-de-agrupamiento-jer%C3%A1rquico-en-python-b3472codd829>
- Valdés García, D., Reyes Chirino, R., Alexander Jaime Infante, R., Figueroa Cabrera, E., & Alejandro Suárez Hernández, J. (2021). REVISTA CUBANA DE TRANSFORMACIÓN DIGITAL ARTÍCULO ORIGINAL Método de Clustering Jerárquico Aglomerativo para la asignación del financiamiento a Proyectos de Desarrollo Local Hierarchical Agglomerative Clustering Method for the allocation of financing to Local Development Projects UNIVERSIDAD DE PINAR DEL RÍO “HERMANOS SAÍZ MONTES DE OCA”, CUBA. *REVISTA CUBANA DE TRANSFORMACIÓN DIGITAL*. <https://orcid.org/0000-0002-0098-5693>
- Vallalta, J. F. (2022). *Aprendizaje supervisado y no supervisado - healthdataminer.com*. Health Data Miner.
- Xie, Q. (2024). Application of Q-learning algorithm based on heterogeneous sensor networks in higher education teaching management. *Measurement: Sensors*, 33, 101188. <https://doi.org/10.1016/J.MEASEN.2024.101188>
- Yacoub, M. H., Ismail, S. M., Said, L. A., Madian, A. H., & Radwan, A. G. (2024). Reconfigurable hardware implementation of K-nearest neighbor algorithm on FPGA. *Int. J. Electron. Commun. (AEÜ)*, 173, 154999. <https://doi.org/10.1016/j.aeue.2023.154999>

VI. ANEXOS

Anexo 01. Matriz de operacionalización de Variables.

Problema	Objetivos	Hipótesis	Variables	Dimension	Indicadores	Escalas de medición	Metodología			
General			Variable Independiente: Machine Learning	Aprendizaje supervisado	Regresión lineal	Regresión	1 Tipo de investigación: Aplicada predictiva. 2. Nivel de investigación: Explicativo. 3. Diseño: No experimental, tipo longitudinal 4. Población y muestra Datos históricos de casos de malaria en Perú, conformado por todos los casos de malaria registrados en la Red Nacional de Epidemiología (RENACE). La muestra lo conforma los casos de malaria en Perú desde los años 2000 al 2022 PROCEDIMIENTO DE RECOPIACIÓN DE DATOS: 5. Preprocesamiento de datos 5.1. Limpieza: Manejo de datos faltantes, detección y corrección de errores. 5.2. Transformación: Normalización, escalamiento, creación de nuevas características 6. Selección y entrenamiento de modelos: 6.1. Modelos de Machine Learning: 6.1.1. Predicción: 6.1.2. Utilizar el modelo seleccionado para predecir los casos de malaria en el futuro periodo de tiempo deseado. Generar intervalos de confianza para las predicciones. 6.1.3. Interpretación y visualización: 6.1.4. Analizar la importancia de las variables predictoras para entender los factores que más influyen en la transmisión de la malaria. 6.1.5. Visualizar los resultados de las predicciones en mapas y gráficos para facilitar la comunicación y toma de decisiones.			
Mediante el manejo de Machine Learning y los casos de malaria de 2000 al 2022, ¿es posible determinar con precisión las áreas con mayor riesgo de incidencia de malaria para 2027?	Desarrollar un modelo de predicción preciso y confiable que determine las áreas con mayor riesgo de incidencia de malaria para 2027.	Es posible desarrollar un modelo de predicción preciso y confiable de incidencia de malaria en Perú al 2027, utilizando técnicas de Machine Learning y el conjunto de datos de casos de malaria del 2000 al 2022, que permita identificar con precisión las áreas con mayor riesgo de malaria.			K-Nearest Neighbours					
					Regresión logística	Clasificación				
					Árboles de desición					
					Bosque aleatorio					
					Máquinas de vectores de soporte (SVM)					
					Gradient Boosting					
					Redes neuronales artificiales					
		Aprendizaje no supervisado		K-means	Clustering					
				Clustering jerárquico						
		Aprendizaje por refuerzo		Modelos de mezcla gaussiana (GMM)	Optimización de políticas					
Específico										
Identificando los casos de malaria en las distintas ubicaciones geográficas mediante machine learning, ¿es posible predecir brotes de malaria en las regiones del país?	Analizar las variables departamento, provincia, distrito, localidad, ubigeo y localcod para identificar y mapear las áreas geográficas con mayor incidencia de malaria.	Es posible identificar las zonas geográficas más afectadas por la malaria, con el fin de predecir futuros casos de malaria.	Variable Dependiente: Malaria	Epidemiológico	departamento	Nominal				
Identificando la frecuencia de los distintos tipos de malaria en las regiones del país mediante machine learning, ¿es posible predecir los casos de malaria en esas regiones?	Analizar las variables enfermedad y diagnostic para estudiar las diferentes presentaciones y diagnósticos de la malaria.	Es posible identificar los tipos de malaria que más afectan a cierta región, con el fin de predecir los casos de malaria.			provincia					
					distrito					
					localidad					
					enfermedad					
Identificando los factores demográficos mediante machine learning, ¿es posible predecir la vulnerabilidad de cierta población a la malaria?	Analizar las variables sexo, edad y tipo_edad para analizar cómo la malaria afecta a diferentes grupos demográficos.	Es posible predecir los grupos de población vulnerable en los casos de malaria futuros.			diagnostic					
					diresa					
					ubigeo					
					localcod					
Identificando patrones temporales mediante machine learning, ¿es posible predecir épocas del año con mayor prevalencia de malaria ?	Analizar las variables semana y año para detectar patrones estacionales o tendencias temporales en la incidencia de malaria.	Es posible predecir épocas del año con mayor prevalencia de casos de malaria de acuerdo a cada región geográfica.			sexo	Intervalo				
					semana					
					año	Razón				
					edad					
					tipo_edad	Ordinal				